Dataset Cuaca

About Dataset

Dataset ini berisi data cuaca yang digabung dari beberapa kota, dengan fokus pada parameter lingkungan penting.
dibuat oleh Jaydeep Vaishya.
https://www.kaggle.com/datasets/jaydeepvaishya/weather-dataset/data

Informasi yang terdapat:

- Suhu udara:Rata-rata, minimum, maksimum(°C).
- Atmosfer & Radiasi:Tekanan udara(hPa) dan radiasi matahari
- Angin:Kecepatan dan arah angin

Preview Dataset

A	B	C	D	E	F	G	H
Pressure	global_radiation	temp_mean(c)	temp_min(c)	temp_max(c)	Wind_Speed	Wind_Bearing	normalized_label
971.5	0.25	9	7	10.7	0	0	0
972.3	0.97	10.5	6.7	13.5	0	0	0
972.4	0.74	6.5	3.9	9.1	0	0	0
973.2	0.15	5.1	3.7	7.7	0	0	0
975.7	0.12	5.2	2.6	8.3	0	0	0
975.9	0.18	4.9	3.8	7.4	0	0	0
976.8	0.27	5.8	4.4	7.1	0	0	1
976.8	0.35	9.2	7.7	9.2	0	0	0
977.3	0.59	11.2	9.3	13.2	0	0	0
977.7	0.64	9	5.4	12.1	0	0	0
978.9	0.14	2.4	0.6	4.7	0	0	0
979.1	0.18	8.5	6.5	9.6	0	0	0
979.2	0.86	10.4	7.8	13.6	0	0	1
979.7	0.31	8.9	6.8	11	0	0	0
980.6	1.01	3.5	0.6	7.1	0	0	0
980.7	0.2	8.6	5.6	9.6	0	0	0
980.9	2.12	9.5	5.5	14.8	0	0	1
981.1	0.71	8.9	6.5	12.3	0	0	0
981.3	0.69	10	8.6	13.3	0	0	0

weather_dataset

Accessibility: Unavailable

8 Variabel
533313 Data

Statistik Deskriptif

```
df.describe()
```

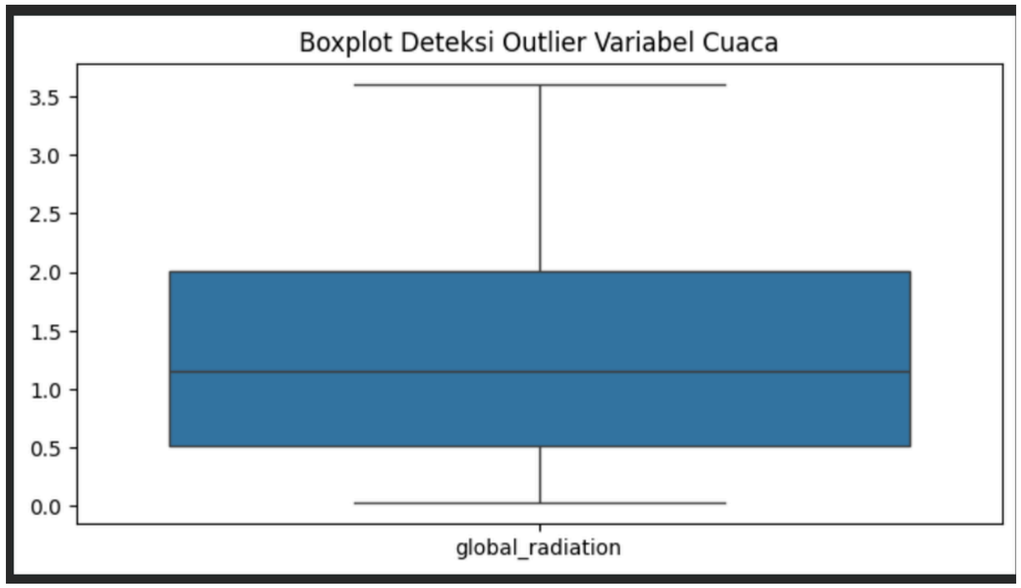
	Pressure	global_radiation	temp_mean(c)	temp_min(c)	temp_max(c)	Wind_Speed	Wind_Bearing	normalized_label
count	253616.000000	253616.000000	253616.000000	253616.000000	253616.000000	253615.000000	253615.000000	253615.000000
mean	1008.889232	1.144917	11.762536	8.067618	15.737767	12.855659	195.031942	0.931609
std	2.988525	0.814164	6.356628	5.878953	7.386196	7.997605	97.405187	1.024541
min	971.500000	0.030000	-11.100000	-16.000000	-8.500000	0.000000	0.000000	0.000000
25%	1007.600000	0.430000	7.100000	3.700000	10.400000	6.620000	140.000000	0.000000
50%	1009.700000	0.960000	12.200000	8.400000	15.800000	11.270000	190.000000	1.000000
75%	1011.100000	1.740000	16.600000	12.800000	21.000000	16.970000	280.000000	2.000000
max	1012.100000	3.570000	27.900000	21.500000	36.200000	47.090000	359.000000	3.000000

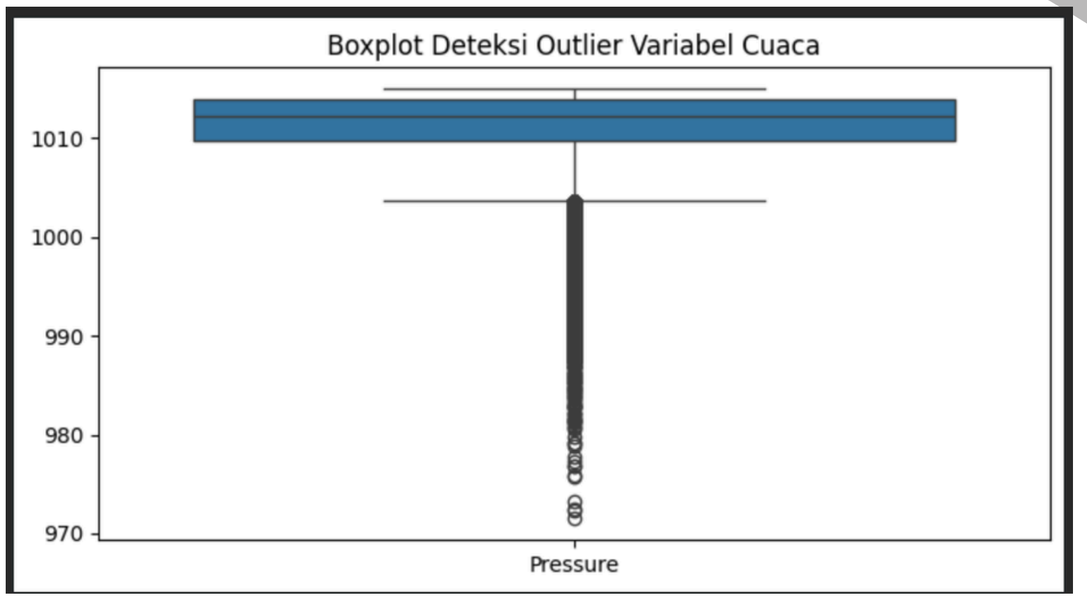
→ temp_mean(c) (Suhu Rata-rata): Memiliki nilai rata-rata (mean) sebesar 11.76°C dengan suhu terendah mencapai -11.10°C dan tertinggi 27.90°C

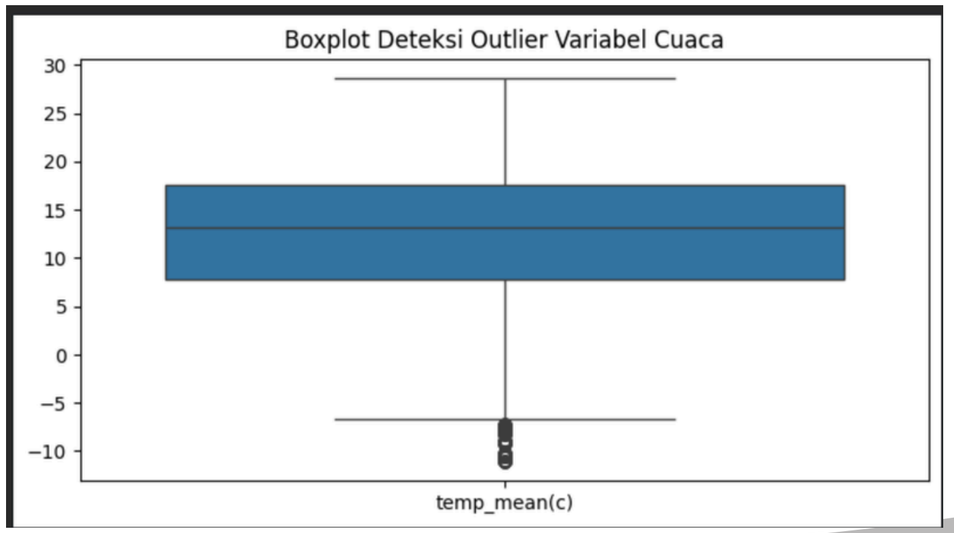
→ global_radiation (Radiasi Global): Memiliki rata-rata sebesar 1.14 dengan sebaran data (std) 0.81

→ Pressure (Tekanan Udara): Memiliki rata-rata tekanan udara sebesar 1008.88 hPa, dengan nilai minimum 971.50 hPa dan maksimum 1012.10 hPa.

Boxplot Deteksi Outlier







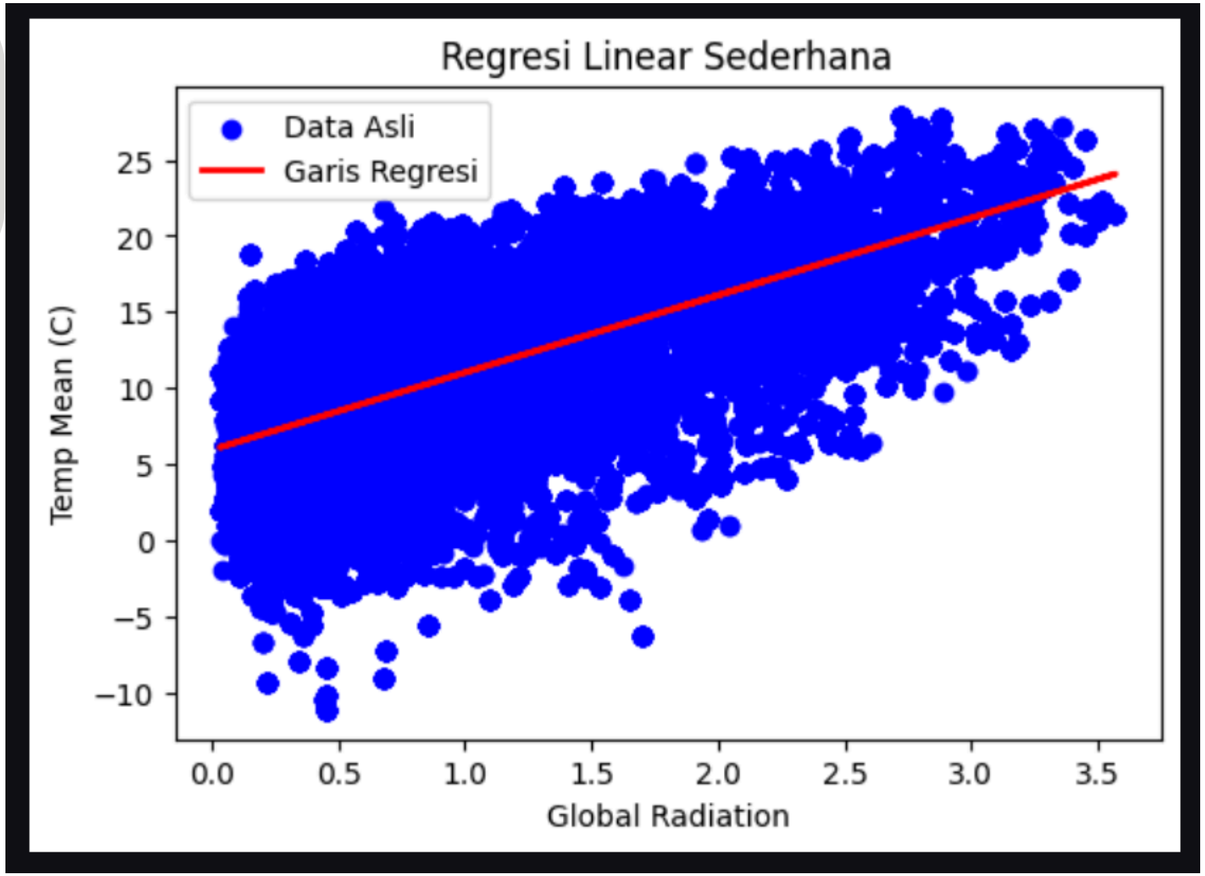
Regresi Linear Sederhana & Fitted Model

```
==========================================
MODEL: REGRESI LINEAR SEDERHANA
==========================================
Persamaan: Y = 6.1063 + 4.9884 * X
MAE  : 3.8175
RMSE : 4.7304
R2   : 0.4726
```

```
Koefisien: [4.98839178]
Intercept: 6.1062922718447705
```

- Tanpa radiasi (0): Suhu udara diperkirakan ada di 6.1063 °C.
- Radiasi naik 1 unit: Suhu udara bakal ikutan naik sebesar 4.9884 °C.
- Dengan X sebagai global radiation
- R2 (0,4726): Radiasi matahari menjelaskan 0,4726 variasi suhu.
- MAE (3,8175 °C): Rata-rata error prediksi sebesar 3.8175 °C.
- RMSE (4,7304°C): Tingkat error model sebesar 4.7304 °C

Visual Regresi Linear Sederhana



- Garis merah menunjukkan hubungan positif/searah. Semakin tinggi radiasi matahari (Sumbu X), semakin tinggi pula perkiraan suhu rata-rata (Sumbu Y). Sebaran titik biru menunjukkan data aktual di sekitar garis regresi.

Kenapa Memilih Variable Y dan X Pada Regresi Linear Sederhana

Alasan pemilihan variabel Target (Y) yaitu temp_mean(c) adalah karena suhu rata-rata merupakan indikator utama kondisi iklim yang penting untuk diprediksi. Sementara itu, variabel prediktor (X) yang dipilih meliputi global_radiation dan Pressure karena berdasarkan ilmu meteorologi, energi radiasi matahari dan tekanan udara memiliki hubungan fisik yang kuat dan signifikan terhadap fluktuasi temperatur udara di permukaan bumi

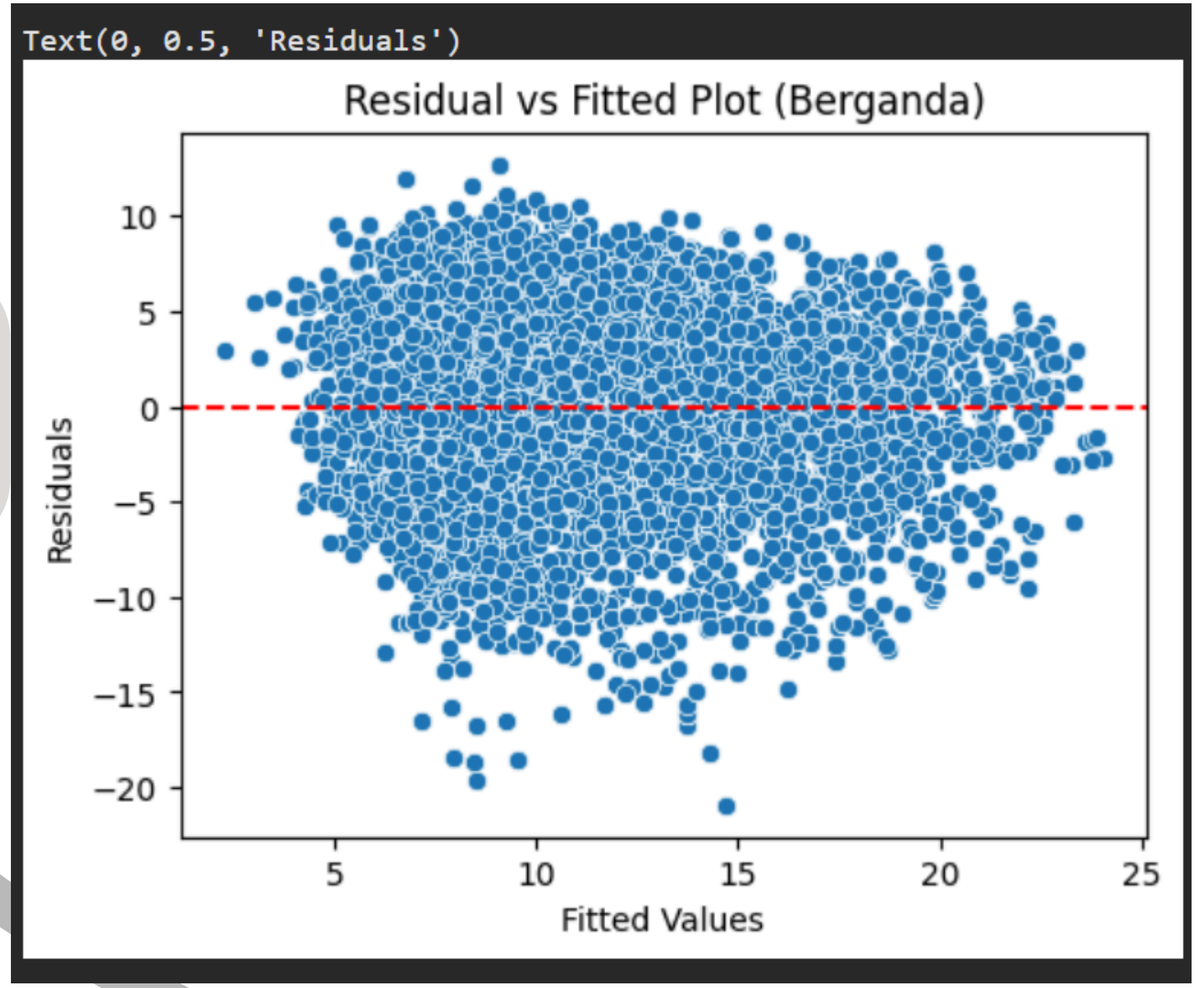
Regresi Linear Berganda & Fitted Model

```
========================================
MODEL: REGRESI LINEAR BERGANDA
========================================
Persamaan: Y = -129.6335 + 4.9769 * X1 + 0.1345 * X2
MAE  : 3.8926
RMSE : 4.8228
R2   : 0.4260
```

```
Koefisien: [4.97690878 0.13450328]
Intercept: -129.63346179607774
```

- Radiasi Matahari: Tetap berpengaruh dominan. Tiap naik 1 unit radiasi, suhu naik 4.9769 °C.
- Tekanan Udara: Tiap tekanan udara naik 1 unit, suhu cuma naik 0. 1345°C.
- Dengan X1 sebagai Radiasi dan X2 sebagai Tekanan udara
- Intercept/Konstanta (-129.63): Estimasi suhu udara ketika radiasi matahari dan tekanan udara bernilai 0

Visualisasi Regresi Linear Berganda

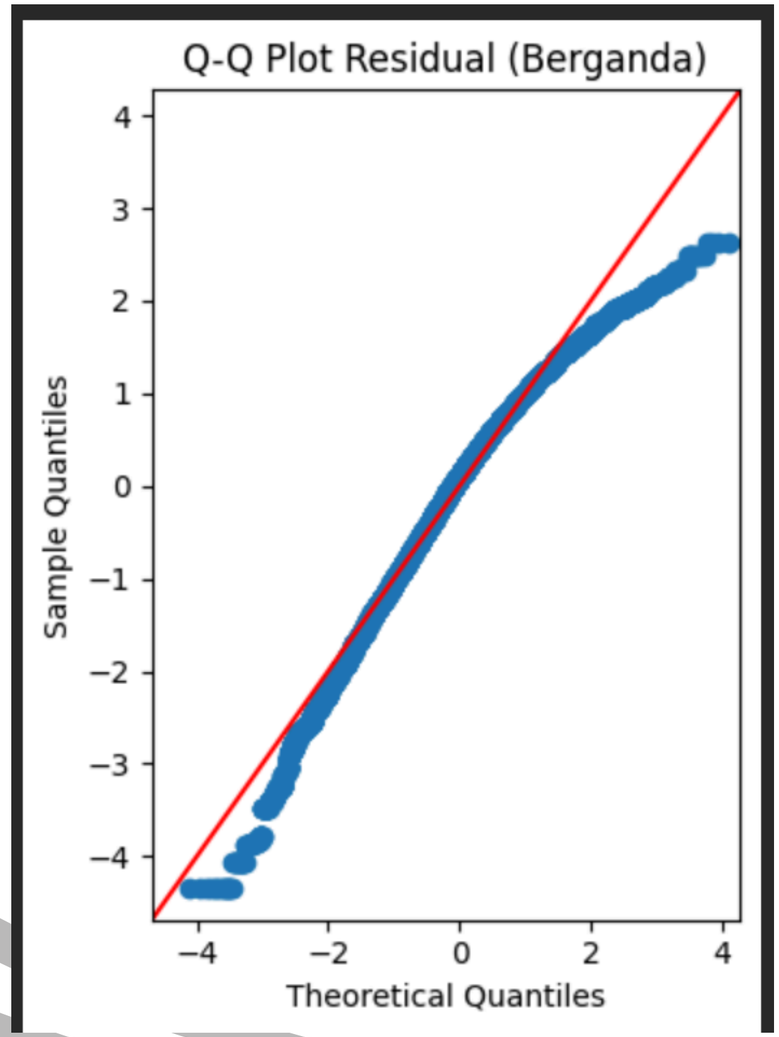


- Sebaran titik error masih agak berpola dan tidak tersebar rata sempurna di sekitar garis 0.
- Artinya Masih ada variasi error yang belum sepenuhnya tertangkap oleh model linear.

Kenapa Memilih Variable Y dan X Pada Regresi Linear Berganda

Menggabungkan nilai prediksi di sumbu X dan residual di sumbu Y bertujuan untuk melihat apakah besarnya error bertambah besar/kecil seiring tingginya nilai prediksi.
Dan juga melihat pola non-linear, titik-titik acak tersebar merata di sekitar garis nol tanpa membentuk pola tertentu (seperti pola corong atau kurva). Jika ada pola, berarti ada hubungan non-linear yang belum tertangkap oleh model.

Q-Q Plot



- Titik-titik biru melenceng jauh dari garis merah di ujung kiri dan kanan.
- Artinya Data residual tidak terdistribusi normal sempurna karena ada nilai-nilai ekstrem (outlier) pada data cuaca.

Kenapa Memilih Variable Y dan X Pada Q-Q Plot

Pemilihan sumbu X (nilai teoritis normal) dan sumbu Y (nilai nyata sampel) dilakukan untuk membandingkan sebaran error model kita dengan acuan distribusi normal ideal.

Dan juga melihat penyimpangan ekstrem (Outlier), jika titik-titik pada sumbu Y menempel sejajar pada garis diagonal acuan (garis merah), artinya residual berdistribusi normal. Jika titik melenceng jauh di ujung-ujung grafik, ini menandakan adanya outlier atau nilai ekstrem pada data cuaca.

Kesimpulan

- Model sederhana menghasilkan performa yang lebih tinggi (R2 = 0.4726) dan tingkat kesalahan yang lebih rendah (MAE=3.82, RMSE = 4.73) dibandingkan Regresi Berganda.
- Faktor Paling Dominan:Radiasi matahari (global_radiation) terbukti menjadi prediktor utama penentu suhu udara rata-rata.
- Menambahkan variabel tekanan udara (Pressure) tidak memberikan kontribusi signifikan terhadap akurasi prediksi.
- Berdasarkan grafik Residual dan Q-Q Plot, data cuaca memiliki beberapa nilai ekstrem (outlier) yang membuat sebaran error belum berdistribusi normal sempurna.

Thank You